CURSO: CC471 2019

Practica 05.

LAZARO CAMASCA EDSON

PRACTICA: Introducción a Biopython: Lectura y escritura de archivos de secuencias

Conteo de registros

Se puede contar el número de proteínas en el archivo NC_000913.faa utilizando grep: el símbolo "^>" indica búsqueda del símbolo ">" al inicio de la línea, es decir buscamos registros (proteínas) en formato Fasta.

P1. Cree el archivo count_fasta.py con el código anterior y modifíquelo utilizando sys.argv para que pueda recibir el nombre del archivo como parámetro y devuelva correctamente los resultados. p. ej utilizando for filename in sys.argv[1:]:

```
ifrom Bio import SeqI0
import sys
import sys
import sys
import ("This is the name of the script: ", sys.argv[0])
import ("The arguments are: ", len(sys.argv))
import ("The arguments are: ", str(sys.argv))

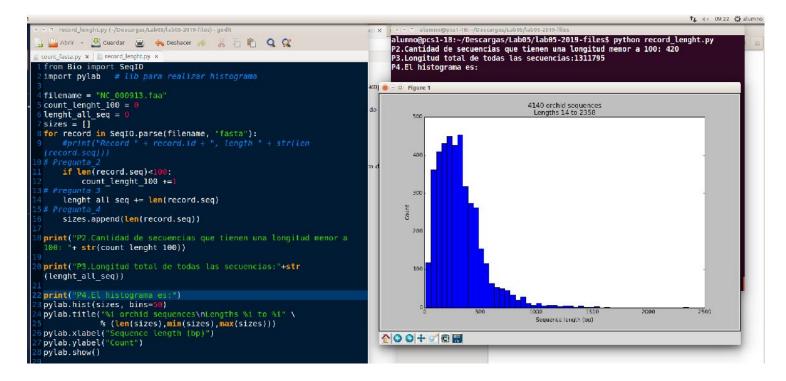
fritename = "NC 000913.faa"
import ("Number of arguments are: ", str(sys.argv))

filename = "NC 000913.faa"
import ("Number of arguments are: ", 'count_fasta.py NC_000913.faa
'('Number of arguments: ', 2)
'('Number
```

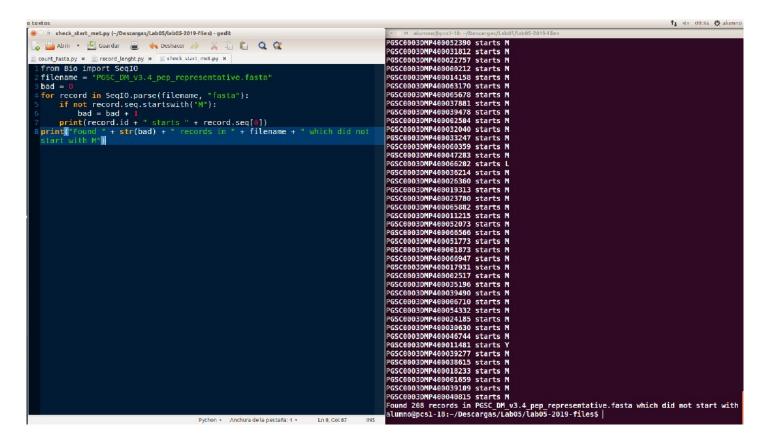
Analizando los registros

La función SeqIO.parse crea objetos SeqRecord. Los objetos SeqRecord de Biopython son un contenedor que contiene la secuencia y cualquier anotación al respecto de ella, lo más importante es su identificador.

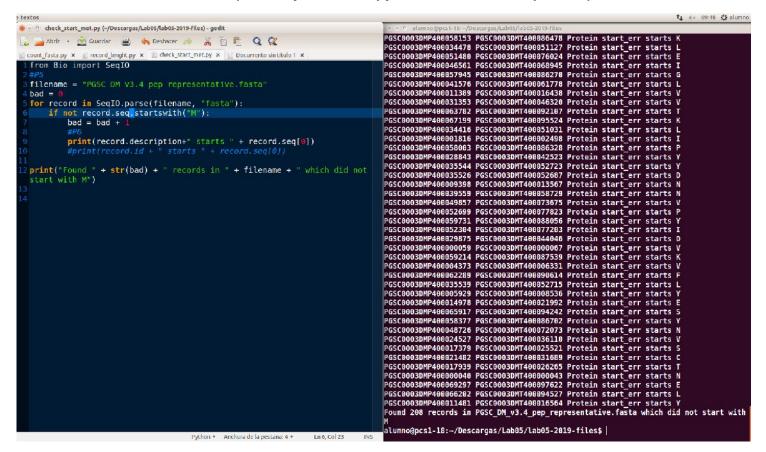
- P2. Ejercicio: Cuente cuantas secuencias tienen menos de 100 aminoácidos de longitud.
- P3. Ejercicio: Cuente cual es la longitud total de todas las secuencias.
- P4. Ejercicio. Dibuje un histograma de la distribución de longitudes. [ref. 3]



P5: ¿Cuantas de las proteínas de E. coli de este conjunto se encontraron? Un conjunto de secuencias con "cero registros que no empiezan con M "significa que ha sido correctamente anotado y estandarizado.



P6. Modifique el programa para imprimir la descripción de los registros con problemas, no solo sus identificadores. (Lea la ayuda de Biopyhthon acerca de SeqRecord)



Verificando los caracteres de Parada

P7. Escriba un programa check_stops.py para contar el número de secuencias con un "*" en ellas (en cualquier parte) Y el número de secuencias con el "*" al final. Pruebe el programa con PGSC_DM_v3.4_pep_representative. fasta.

```
check_stops.py
temp.py 🖾 P8.py 🖾 convert_gb_to_fasta.py 🖾
  1 from Bio import SeqIO
  2 #P7
  3 filename = "PGSC_DM_v3.4_pep_representative.fasta"
  4 \text{ bad} = 0
  5 final_stop = 0
  6 for record in SeqIO.parse(filename, "fasta"):
       if record.seq[-1] == '*':
  8
           final_stop +=1
  9
       for i in record.seq:
  10
           if i == '*':
 11
               bad +=1
 12
               #print(record.description+" starts " + record.seq[0])
 13
 14
               break
 15
 16 print("Secuencias que tienen un *: "+str(bad))
 17 print("Secuencias que tienen un * al final: "+str(final stop))
 18
Terminal de IPython
Terminal 1/A 🔯
```

In [11]: runfile('E:/Lab05/lab05-2019-files/check_stops.py', wdir='E:/Lab05/lab05-2019-files')
Secuencias que tienen un *: 39031
Secuencias que tienen un * al final: 39031

P8 cuál es el resultado del siguiente código?

```
temp.py P8.py convert_gb_to_fasta.py

1 from Bio import SeqIO

2 #FORMATO FASTA
4 fasta_record = SeqIO.read("NC_000913.fna", "fasta")
5 print("Formato fasta: "+fasta_record.id + " length " + str(len(fasta_record)))

6 #FORMATO GBANK
8 genbank_record = SeqIO.read("NC_000913.gbk", "genbank")
9 print("formato gebank: "+genbank_record.id + " length " + str(len(genbank_record)))

Terminal de IPython

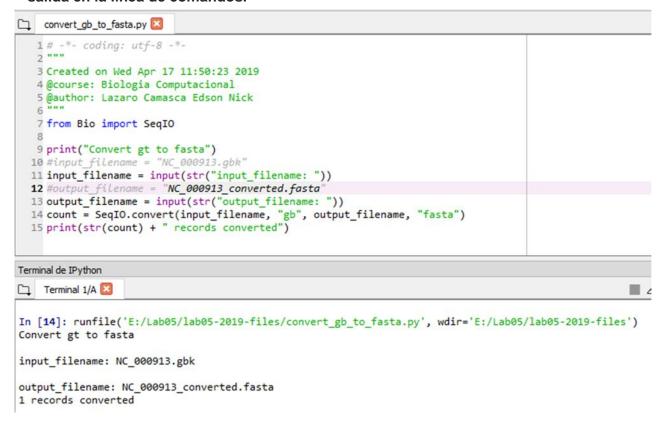
Terminal 1/A 

Terminal 1/A
```

In [7]: runfile('E:/Lab05/lab05-2019-files/P8.py', wdir='E:/Lab05/lab05-2019-files')
Formato fasta: gi|556503834|ref|NC_000913.3| length 4641652
formato gebank: NC_000913.3 length 4641652

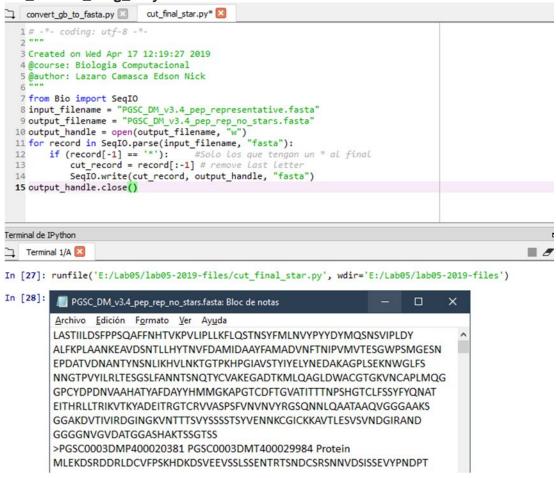
Convertir un archivo de secuencias

P9: Modifique este programa para que el programa reciba el archivo de entrada y el de salida en la línea de comandos.



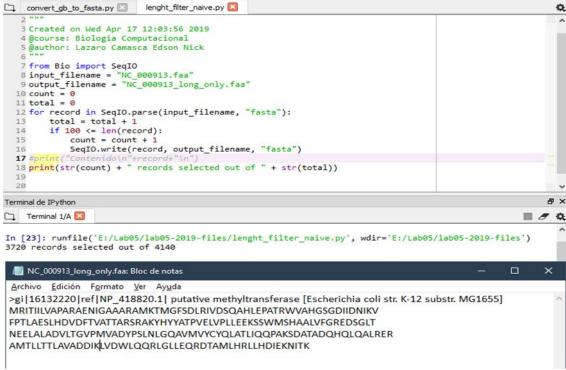
Filtrando un archivo de secuencias.

P10: ¿Cuál es el resultado de ejecutar este programa? Que contiene NC 000913 long only.faa?.



P11: ¿Cuál es el resultado de correr el siguiente comando? ¿Y qué significa? \$ grep -c "^>" NC_000913_long_only.faa

P12: Modifique el programa para que remueva la última letra solo si es "*" pero que deje el registro sin cambio si no termina en "*" póngale nombre cut_final_star.py



P13: Cree el programa filter_wanted_ids.py que escribe las proteínas requeridas del archivo de proteínas de la papa.

```
convert_gb_to_fasta.py
                            filter_wanted_ids.py
                                                 filter wanted ids read txt.py
  1 # -*- coding: utf-8 -*-
   3 Created on Wed Apr 17 12:35:37 2019
   4 @course: Biologia Computacional
  5 @author: Lazaro Camasca Edson Nick
   7 from Bio import SeqIO
   8 wanted_ids = ["PGSC0003DMP400019313", "PGSC0003DMP400020381", "PGSC0003DMP400020972"]
   9 input_filename = "PGSC_DM_v3.4_pep_representative.fasta"
  10 output_filename = "wanted_potato_proteins.fasta"
  11 count = 0
  12 total = 0
  13 output_handle = open(output_filename, "w")
  14 #
  15 # Your code here
  16 for record in SeqIO.parse(input_filename, "fasta"):
  17
        total +=1
                     La sequencias queridas
Terminal de IPython
Terminal 1/A 🔝
In [48]: runfile('E:/Lab05/lab05-2019-files/filter wanted ids.py', wdir='E:/Lab05/lab05-2019-files')
3 records selected out of 39031
```

P14: Modifique el programa para leer la lista de identificadores requeridos de un archivo de texto. Un ld por línea.

```
filter_wanted_ids_read_txt.py
   7 from Bio import SeqIO
   8 wanted_ids = []
  10 #ingresar "wanted ids.txt"
  11 #f = open(input(str("Ingrese la direccion del fichero wanted_ids: ")))
  12 f = open("wanted ids.txt")
  13 for linea in f:
       wanted_ids.append(f.readline())
  15
  16 f.close()
  18 input_filename = "PGSC_DM_v3.4 pep_representative.fasta"
  19 output_filename = "wanted_potato_proteins.fasta"
  20 count = 0
  21 total = 0
  22 output_handle = open(output_filename, "w")
                                                                                                           Ð
Terminal de IPython
Terminal 1/A
                                                                                                       # 8 ·
In [57]: runfile('E:/Lab05/lab05-2019-files/filter_wanted_ids_read_txt.py', wdir='E:/Lab05/lab05-2019-
files')
1 records selected out of 39031
```

P15: Complete el siguiente programa filter_wanted_id_in_order.py usando SeqlO.index(...) para hacer un archivo fasto con registros que queremos en el orden especifico mostrado.

```
8 wanted_ids = ["PGSC0003DMP400019313", "PGSC0003DMP400020381", "PGSC0003DMP400020972"]
  9 fileName = 'PGSC_DM_v3.4_pep_representative.fasta'
 10 output = 'wanted potato proteins in order.fasta'
 11 fasta_index = SeqIO.index(fileName, 'fasta')
  12 total = len(fasta_index)
 13 print (str(total) + " secuencias en "+fileName)
 14 cont = 0
 15 output_handle = open(output, 'w')
 17 for record_id in wanted_ids:
      cont = cont + 1
        record = fasta_index[record_id]
 19
  20
        SeqIO.write(record, output_handle, 'fasta')
  21
  22 output_handle.close()
  23 print(str(cont)+" secuencias selecionadas de "+str(total))
  24
Terminal de IPython
Terminal 1/A 🖾
In [53]: runfile('E:/Lab05/lab05-2019-files/filter_wanted_id_in_order.py', wdir='E:/Lab05/lab05-2019-
files')
39031 secuencias en PGSC DM v3.4 pep representative.fasta
3 secuencias selecionadas de 39031
```